

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ ОБРАЗОВАТЕЛЬНОЕ БЮДЖЕТНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«ФИНАНСОВЫЙ УНИВЕРСИТЕТ ПРИ ПРАВИТЕЛЬСТВЕ
РОССИЙСКОЙ ФЕДЕРАЦИИ»
(ФИНАНСОВЫЙ УНИВЕРСИТЕТ)**

**Кафедра искусственного интеллекта
Факультета информационных технологий и анализа больших данных**

Дисциплина: «Машинное обучение в семантическом и сетевом анализе»

Направление подготовки: «Прикладная математика и информатика»

Профиль: «Прикладное машинное обучение»

Факультет информационных технологий и анализа больших данных

Форма обучения очная

Учебный 2025/2026 год, 6 семестр

**Курсовая работа на тему:
«Применение методов машинного обучения для анализа сетей цитирования научных
работ»**

Выполнил:

студент группы ПМ22-1

Кидысюк А.В.

Научный руководитель:

Мацеевич С.В.

Москва 2026

СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....	24
1. ТЕОРЕТИЧЕСКАЯ ЧАСТЬ.....	27
1.1. ПОСТАНОВКА ЗАДАЧИ ПРЕДСКАЗАНИЯ СВЯЗЕЙ (LINK PREDICTION) В СЕТЯХ ЦИТИРОВАНИЯ.....	27
1.2. ПРОБЛЕМА ХОЛОДНОГО СТАРТА ДЛЯ НОВЫХ ПУБЛИКАЦИЙ И ПУТИ ЕЕ РЕШЕНИЯ.....	27
1.3. ОБЗОР МЕТОДОВ ВЕКТОРНОГО ПРЕДСТАВЛЕНИЯ ТЕКСТОВ И ТОПОЛОГИИ ГРАФОВ.....	28
СЕМАНТИЧЕСКОЕ ПРЕДСТАВЛЕНИЕ ТЕКСТОВЫХ ДАННЫХ.....	28
ТОПОЛОГИЧЕСКОЕ ПРЕДСТАВЛЕНИЕ СТРУКТУРЫ ГРАФА.....	28
1.4. ОГРАНИЧЕНИЯ ГОМОГЕННЫХ ГРАФОВЫХ НЕЙРОННЫХ СЕТЕЙ.....	29
ЭФФЕКТ ИЗБЫТОЧНОГО СГЛАЖИВАНИЯ (OVER-SMOOTHING).....	29
ОТСУТСТВИЕ ЛОКАЛЬНОЙ ГОМОФИЛИИ ДЛЯ НОВЫХ УЗЛОВ.....	29
1.5. ВЫВОДЫ ПО ГЛАВЕ 1.....	30
2. МЕТОДОЛОГИЯ ИССЛЕДОВАНИЯ И ПРЕДВАРИТЕЛЬНЫЙ АНАЛИЗ ДАННЫХ.....	31
2.1. ОПИСАНИЕ НАБОРА ДАННЫХ OPENALEX И СТРУКТУРЫ ГРАФА.....	31
2.2. ПРЕДВАРИТЕЛЬНАЯ ОБРАБОТКА, ПРУНИНГ И ВЫДЕЛЕНИЕ ПЛОТНОГО ЯДРА (-CORE).....	32
2.3. АНАЛИЗ ГРАФА.....	33
ВРЕМЕННАЯ ДИНАМИКА ПЛОТНОСТИ ГРАФА.....	35
2.4. ВЫВОДЫ ПО ГЛАВЕ 2.....	37
3. ПРАКТИЧЕСКАЯ ЧАСТЬ: КОНСТРУИРОВАНИЕ ПРИЗНАКОВ И РАЗРАБОТКА МОДЕЛЕЙ.....	38
3.1. СЕМАНТИЧЕСКОЕ КОДИРОВАНИЕ ТЕКСТОВ (SciBERT + AUTOENCODER).....	38
3.2. ТОПОЛОГИЧЕСКОЕ ЭМБЕДДИНГИ ГРАФА (FASTRP).....	39
3.3. РАСЧЕТ ЭВРИСТИЧЕСКИХ ПРИЗНАКОВ НА ГЕТЕРОГЕННОМ ГРАФЕ.....	40
3.4. МЕТОД МАСКИРОВАНИЯ РЕБЕР И ГЕНЕРАЦИЯ НЕГАТИВНЫХ ПРИМЕРОВ.....	42
3.5. АРХИТЕКТУРЫ МОДЕЛЕЙ: ГОМОГЕННЫЕ И ГЕТЕРОГЕННЫЕ GNN И GBDT-РАНЖИРОВАНИЕ.....	42
ГЕТЕРОГЕННЫЕ ГРАФОВЫЕ НЕЙРОННЫЕ СЕТИ.....	44
ГРАДИЕНТНЫЙ БУСТИНГ (GBDT).....	44
3.6. ОПТИМИЗАЦИЯ ФУНКЦИЙ ПОТЕРЬ (BPR, INFO NCE, MARGIN, FOCAL LOSS, ASL).....	45
3.7. ВЫВОДЫ ПО ГЛАВЕ 3.....	46
4. АНАЛИЗ ПОЛУЧЕННЫХ РЕЗУЛЬТАТОВ.....	47
4.1. МЕТРИКИ ОЦЕНКИ КАЧЕСТВА РАНЖИРОВАНИЯ (MRR, HITS@10).....	47
4.2. РЕЗУЛЬТАТЫ ПЕРВОГО ЭКСПЕРИМЕНТА: ГОМОГЕННЫЕ GNN НА ГРАФЕ ЦИТИРОВАНИЙ.....	48
ТОПОЛОГИЧЕСКИЙ АНАЛИЗ И ВЛИЯНИЕ ФУНКЦИЙ ПОТЕРЬ	49
4.3. РЕЗУЛЬТАТЫ ВТОРОГО ЭКСПЕРИМЕНТА: ГЕТЕРОГЕННОЕ ПРЕДСТАВЛЕНИЕ И GBDT-РАНЖИРОВАНИЕ.....	50
АНАЛИЗ ПРЕДСКАЗАНИЙ В УСЛОВИЯХ ХОЛОДНОГО СТАРТА	51
4.4. ПРЕДСКАЗАНИЕ И ОЦЕНКА ЛУЧШЕГО РЕШЕНИЯ В УСЛОВИЯХ ХОЛОДНОГО СТАРТА.....	52
4.5. ВЫВОДЫ ПО ГЛАВЕ 4.....	53
ЗАКЛЮЧЕНИЕ.....	54
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ.....	57
ПРИЛОЖЕНИЕ А: ТАБЛИЦА ПЕРВОГО ЭКСПЕРИМЕНТА.....	58
ПРИЛОЖЕНИЕ Б: ТАБЛИЦА ВТОРОГО ЭКСПЕРИМЕНТА.....	61
ПРИЛОЖЕНИЕ В: ПРОГРАММНЫЙ КОД.....	62

Введение

Актуальность темы:

Экспоненциальный рост объема научной литературы во всех областях знаний усложняет процесс поиска релевантных источников и проверки научных гипотез. Автоматизация анализа структуры научных знаний и построение систем рекомендаций научной литературы являются востребованными прикладными и исследовательскими задачами. Ключевой проблемой таких систем является "холодный старт" - появление новых публикаций, которые еще не встроены в топологию графа цитирований (то есть не имеют входящих и исходящих ребер). Традиционные методы сетевого анализа, основанные на локальной топологии (например, подсчет общих соседей), для новых статей не применимы.

Объект исследования:

Сети цитирования научных публикаций и соавторства, представленные в виде ориентированных гомогенных и гетерогенных графов.

Предмет исследования:

Модели, методы и алгоритмы машинного обучения (включая графовые нейронные сети, полносвязные архитектуры и градиентный бустинг на графах), применяемые для решения задачи предсказания связей в условиях холодного старта.

Цель работы:

Разработка, сравнение результатов экспериментов и топологический анализ эффективности моделей машинного обучения для предсказания связей для новых публикаций на основе текстовых признаков, структурных проекций соавторства и эвристик сетевого анализа.

План работы:

1. Собрать и предобработать массив данных о научных публикациях из открытой платформы OpenAlex, сформировав гетерогенную структуру "статья-автор".
2. Проанализировать полученный граф, описать статистические и топологические свойства: распределение степеней вершин, временную динамику плотности связей.
3. Векторизовать данные графа (название, тэги и абстракт), и создать эвристики на основе свойств графа.
4. Определить метод разбиения, и разбить массив вершин графа на обучающую, валидационную и тестовую выборки.
5. Обучить модели на созданных выборках
 - 5.1 Реализовать и обучить семейство гомогенных графовых нейронных сетей (GCN, LightGCN, SGC, SAGE, NeoGNN) с оптимизацией ранжирующих функций потерь (BPR, Margin, InfoNCE).
 - 5.2. Реализовать двухстадийный алгоритм ранжирования на базе градиентного бустинга CatBoostRanker с использованием списочных целевых функций (YetiRank, QueryRMSE).
6. Провести сравнительный анализ результатов и на основе различия в метриках (MRR, Hits@10, NDCG) сделать выводы о структурных свойствах исследуемого графа и ограничениях сверточных подходов на семантически плотных сетях.

Практическая значимость работы:

Разработанные алгоритмы могут быть непосредственно интегрированы в академические поисковые системы, цифровые библиотеки и платформы автоматизации научной деятельности для предиктивного подбора списка литературы на этапе написания черновика статьи

1. Теоретическая часть

1.1. Постановка задачи предсказания связей (Link Prediction) в сетях цитирования

Сеть цитирования научных работ — ориентированный граф, где ребро означает наличие цитирования. Каждой вершине сопоставлен год публикации. Статьи из прошлого не могут цитировать статьи из будущего. Это хронологическое ограничение строго учитывается при тренировке и предсказании.

Задача предсказания связей формулируется как вычисление функции оценки, определяющей вероятность возникновения ребра между парой вершин. В контексте рекомендательных систем и поисковой выдачи задача сводится к ранжированию кандидатов: для заданной статьи-запроса необходимо сформировать список наиболее вероятных целевых вершин, максимизируя метрики ранжирования на подмножестве истинных ребер.

1.2. Проблема холодного старта для новых публикаций и пути ее решения

Для новой публикации, поступающей в систему, исходное множество инцидентных ребер пусто (степени входа и выхода равны нулю). Данное состояние классифицируется как задача холодного старта (cold start) на графах.

Классические топологические методы сетевого анализа, основанные на локальной структуре окрестностей (такие как общий подсчет соседей, индекс Adamic-Adar, коэффициент Жаккара), в данном сценарии не функционируют, так как для любого кандидата пересечение их окрестностей пусто.

Для преодоления этого ограничения гомогенный граф преобразуется в гетерогенный (двудольный) вид, включающий множества вершин статей и авторов, а также ориентированные ребра цитирования и ненаправленные ребра авторства.

При поступлении новой статьи в граф вводятся ребра авторства. Это связывает изолированную вершину статьи с существующей топологией авторов. Топология графа статей и авторов позволяет связывать авторов в группы (автор - статья - автор) и взвешивать статьи по авторитетности автора / команды исследователей.

1.3. Обзор методов векторного представления текстов и топологии графов

Семантическое представление текстовых данных

Для фиксации семантики научных документов применяется модель SciBERT — специализированная архитектура Transformer, предобученная на корпусе научных публикаций. На выходе модели для каждого документа формируется плотный вектор размерностью 768 для одного текстового атрибута. При конкатенации векторов названия, аннотации и концептов суммарная исходная размерность составляет 2304.

Для снижения вычислительной сложности и предотвращения переполнения видеопамати применяется полносвязный автоэнкодер, сжимающий вектор до латентного представления размерности 256. Оптимизация параметров автоэнкодера выполняется MSE между исходным и восстановленным векторами.

Топологическое представление структуры графа

Для векторизации знания о топологии создаются эмбединги методом FastRP (Fast Random Projection).

Переходная матрица случайного блуждания определяется как отношение матрицы смежности графа цитирования к диагональной матрице степеней.

Генерируется случайная разреженная матрица проецирования.

Топологические эмбединги вычисляются как взвешенная сумма случайных проекций различного порядка, базирующаяся на итерациях переходной матрицы, регулирующих вклад локальных и глобальных связей окрестности.

1.4. Ограничения гомогенных графовых нейронных сетей

Использование стандартных механизмов свертки на гомогенных графах (GCN, GAT, LightGCN, SAGE) в задачах холодного старта и ранжирования семантически плотных графов ограничено двумя математическими эффектами.

Эффект избыточного сглаживания (Over-smoothing)

Применение операции графовой свертки эквивалентно работе фильтра нижних частот, который усредняет признаки вершины и её соседей. При увеличении глубины слоев представления вершин сходятся к единому распределению, пропорциональному степеням вершин, что приводит к потере дисперсии признаков.

В семантически плотных графах, где узлы изначально обладают высоким сходством по SciBERT-векторам, свертка стирает границы между близкими тематическими доменами, делая невозможным точное ранжирование кандидатов.

Отсутствие локальной гомофилии для новых узлов

Сверточные архитектуры опираются на предпосылку локальной гомофилии (смежные узлы обладают похожими признаками). Для изолированного узла операция свертки вырождается в тождественное преобразование собственных признаков, лишая модель возможности извлекать информацию о структуре графа через механизмы агрегации.

В данных условиях многослойный перцептрон и градиентный бустинг, работающие напрямую с конкатенированными векторами признаков без усреднения по ребрам цитирования, сохраняют исходную дисперсию данных. Они извлекают информацию о топологии не через пространственное сглаживание, а через явное сопоставление эвристик и векторных расстояний, что обеспечивает превосходство над сверточными GNN-моделями в сценарии холодного старта.

1.5. Выводы по главе 1

1. Задача предсказания цитирований для новых публикаций формализуется как задача холодного старта на ориентированном графе с хронологическими ограничениями.
2. Использование гетерогенных графов цитирования-авторства позволяет преодолеть структурную изоляцию новых вершин путем трансляции связей через вершины соавторов.
3. Применение автоэнкодеров поверх SciBERT-представлений позволяет эффективно сжать признаковое пространство с сохранением семантической вариативности текстов.
4. Избыточное сглаживание в сверточных GNN-архитектурах приводит к потере дисперсии признаков на плотных графах, что теоретически обосновывает применимость и превосходство моделей прямого распространения (MLP) и градиентного бустинга (GBDT) в индуктивных сценариях.

2. Методология исследования и предварительный анализ данных

2.1. Описание набора данных OpenAlex и структуры графа

Источником данных для исследования выступает открытый каталог научных публикаций OpenAlex. Сбор данных осуществлялся через программный интерфейс (API) платформы. Выгрузка ограничена предметной областью машинного обучения (Machine Learning) за последние 10 лет (хронологический диапазон: 2017–2026 гг.).

Каждая запись набора данных содержит следующие атрибуты:

- **i** (id) - уникальный идентификатор публикации в системе OpenAlex;
- **y** (publication_year) - год публикации;
- **ti** (title) - название статьи;
- **ab** (abstract) - аннотация работы (восстановленная из инвертированного индекса слов);
- **ct** (concepts) - список предметных концептов/тегов;
- **au** (authorships) - идентификаторы авторов публикации;
- **rf** (referenced_works) - список идентификаторов статей, процитированных в данной работе.

Для решения задачи холодного старта на основе этих атрибутов строится гетерогенный двудольный граф соавторства и цитирования, связывающий статьи через авторов.

2.2. Предварительная обработка, прунинг и выделение плотного ядра (k -core)

Графы цитирования в сыром виде характеризуются избыточной разреженностью и высоким уровнем шума (наличие единичных публикаций авторов-однодневок, статей без цитирований). Для обеспечения топологической стабильности сети и удаления маргинальных узлов к двудольной структуре соавторства применен алгоритм выделения плотного ядра (k -core) с порогом $k = 3$. Данный метод итеративно исключает из графа вершины, степень которых (количество инцидентных ребер) меньше 3.

В результате прунинга была получена связная компонента со следующими количественными характеристиками:

- Общее количество вершин (статей) в графе: 59 632;
- Количество ребер цитирования (cites) в обучающей выборке: 101 719.

Стратегия разделения выборки (Splitting & Masking)

Для оценки обобщающей способности моделей и имитации реальных условий работы системы предложена схема разделения данных на обучающую, валидационную и тестовую выборки в соотношении 85% / 5% / 10% по всем вершинам графа:

- Обучающая выборка (Train): 50 688 вершин;
- Валидационная выборка (Val): 2 981 вершина;
- Тестовая выборка (Test): 5 963 вершины.

Обоснование метода разделения: Первоначально протестированный строгий хронологический сплит (temporal split) приводил к смещению домена

обучения: профили активных авторов последних лет отсутствовали в обучающей выборке, что сильно снижало обобщающую способность для тестовых вершин. Для сохранения непрерывности гетерогенной сети авторов была внедрена стратегия случайного маскирования ребер. При этой схеме вершины всех выборок присутствуют в глобальном графе соавторства, что сохраняет топологию авторов, однако ребра цитирования тестовых и валидационных вершин маскируются на этапе обучения и используются строго для оценки качества предсказания.

2.3. Анализ графа




Рисунок 1. Столбчатая диаграмма распределения средних степеней вершин графа по годам




Рисунок 2. Столбчатые диаграммы распределения входящих и исходящих степеней вершин графа по годам

Исследование очищенного графа показало, что распределение входящих степеней подчиняется степенному закону, характерному для безмасштабных сетей. Небольшое число "хабов" (фундаментальных статей) аккумулирует подавляющее большинство цитирований, в то время как плотность распределения быстро падает к длинному хвосту малоцитируемых работ. Распределение исходящих степеней (Out-Degree, количество ссылок в статье) более равномерно, однако также скошено: подавляющее большинство публикаций ссылается на 15–30 источников, что соответствует академическим стандартам оформления работ.

Временная динамика плотности графа



Рисунок 3. Столбчатая диаграмма распределения количества вершин графа по годам в выборках train, val, test




Рисунок 4. Heatmap количества связей статей в графе между вершинами разных лет

Временная динамика плотности графа

- В период относительной стабильности (2020–2024 гг.) средняя степень вершины колеблется в районе ~ 17.5 ;
- В конечной точке окна (2025–2026 гг.) средняя степень падает до ≈ 11 .

Топологическая интерпретация: Данная динамика отражает неравномерность развития области машинного обучения. В периоды технологических прорывов (публикационных "бумов", наблюдаемых in 2017 г. и в 2025–2026 гг. на фоне развития генеративных моделей) в сеть лавинообразно вливается множество новых вершин. Сеть временно становится более разрозненной, фрагментированной и характеризуется низкой средней степенью. В периоды затишья и консолидации знаний (2020–2024 гг.) темпы прироста новых узлов снижаются, а связи между существующими статьями уплотняются, что приводит к росту средней степени вершины до 17.5.

Анализ временных аномалий цитирования (Heatmap-анализ)

При построении матрицы совместной встречаемости годов публикации цитирующей статьи (y_{source}) и цитируемой статьи (y_{target}) на тепловой карте (Heatmap) были обнаружены ненулевые значения выше главной диагонали. Это указывает на формальное нарушение причинности: статьи цитируют работы, у которых год издания больше, чем у них самих ($y_{target} > y_{source}$).

Данная аномалия обусловлена следующими факторами:

- **1. Пост-датирование выпусков журналов:** Статья фактически выходит на сервере препринтов или в печати в 2024 году и ссылается на

работы 2024 года, но официально относится к выпуску журнала за 2023 год.

- **2. Обновление препринтов (ArXiv):** Документы на ArXiv могут сохранять первоначальную дату регистрации (например, 2022 г.), но проходить через несколько итераций обновлений вплоть до 2024 г., вбирая в себя ссылки на более новые работы.

Для исключения утечки информации при расчете эвристик в модели вводится жесткий фильтр: принудительно зануляются любые предсказания связей, направленные из прошлого в будущее, и такие связи не подаются при обучении.

2.4. Выводы по главе 2

1. Исходные данные OpenAlex по машинному обучению за 10 лет были успешно очищены с помощью алгоритма k -core ($k = 3$), что позволило выделить стабильное ядро из 59 632 статей.
2. Внедрена стратегия случайного маскирования ребер (85/5/10), критически важная для сохранения целостности топологии авторов при решении задачи холодного старта.
3. Топологический анализ выявил степенной характер распределения степеней вершин и зафиксировал снижение плотности графа в периоды публикационных бумов (2017, 2025–2026 гг.), что подчеркивает сложность задачи рекомендаций в эти временные промежутки.
4. Выявлены временные аномалии цитирования на тепловой карте, требующие явной алгоритмической фильтрации в практической части исследования.

3. Практическая часть: конструирование признаков и разработка моделей

3.1. Семантическое кодирование текстов (SciBERT + Autoencoder)

Для извлечения семантического контекста публикаций применяется предобученная модель S-SciBERT. На вход модели подаются конкатенированные текстовые поля каждой статьи. Исходный признаковый вектор $\mathbf{x}_{raw} \in \mathbb{R}^{2304}$ формируется как объединение трех независимых представлений:

$$\mathbf{x}_{raw} = [\mathbf{t}_{title} \parallel \mathbf{t}_{abstract} \parallel \mathbf{t}_{concepts}], \quad (3.1)$$

где $\mathbf{t}_{title}, \mathbf{t}_{abstract}, \mathbf{t}_{concepts} \in \mathbb{R}^{768}$ — SciBERT-эмбединги названия, аннотации и концептов соответственно.

Для преодоления размерного проклятия и снижения затрат видеопамяти при обучении графовых моделей вектор $\mathbf{x}_{raw}$ сжимается с помощью нейросетевого автоэнкодера до размерности 256. Архитектура автоэнкодера имеет следующий вид:

1. Кодировщик (Encoder):

$$\mathbf{h}_{enc} = \text{LayerNorm}(\text{GELU}(W_1 \mathbf{x}_{raw} + \mathbf{b}_1)) \quad (3.2)$$

$$\mathbf{z} = W_2 \mathbf{h}_{enc} + \mathbf{b}_2 \quad (3.3)$$

где $W_1 \in \mathbb{R}^{1024 \times 2304}$, $W_2 \in \mathbb{R}^{256 \times 1024}$

На каждом слое применяется регуляризация Dropout с коэффициентом 0.1.

2. Декодировщик (Decoder):

$$\mathbf{h}_{dec} = \text{LayerNorm}(\text{GELU}(W_3 \mathbf{z} + \mathbf{b}_3)) \quad (3.4)$$

$$\hat{\mathbf{x}} = W_4 \mathbf{h}_{dec} + \mathbf{b}_4 \quad (3.5)$$

где $W_3 \in \mathbb{R}^{1024 \times 256}$, $W_4 \in \mathbb{R}^{2304 \times 1024}$.

Обучение выполняется с использованием оптимизатора AdamW на протяжении 40 эпох с минимизацией среднеквадратичной ошибки (MSE).

Полученный вектор $\mathbf{z}_{text} \in \mathbb{R}^{256}$ фиксируется и используется в качестве базового признака вершины.

3.2. Топологическое эмбединги графа (FastRP)

Для извлечения глобальных топологических свойств сети без вычислительно затратного градиентного обучения применяется алгоритм FastRP.

Проецирование выполняется на предобработанной матрице смежности

$A_{sym} \in \{0, 1\}^{N \times N}$, объединяющей ребра цитирования обучающей выборки и ребра двудольного проецирования соавторства.

Вычисляется переходная матрица случайного блуждания:

$$T = D^{-1}A_{sym} \quad (3.6)$$

где D — диагональная матрица степеней вершин.

Случайная проекционная матрица $S \in \mathbb{R}^{N \times 128}$ генерируется один раз.

Финальное топологическое представление вершин $\mathbf{z}_{topo} \in \mathbb{R}^{128}$ вычисляется путем итеративного умножения на переходную матрицу:

$$\mathbf{z}_{topo} = \sum_{l=1}^3 \beta_l T^l S \quad (3.7)$$

Коэффициенты взвешивания шагов блуждания задаются как

$\beta = [1.0, 2.0, 4.0]$ для придания большего веса глобальной структуре окрестности (до 3 шагов блуждания).

Итоговый статический вектор признаков вершины $\mathbf{x}_i \in \mathbb{R}^{385}$ формируется как конкатенация семантического вектора, топологического вектора и стандартизированного года публикации $\bar{y}_i$:

$$\mathbf{x}_i = [\mathbf{z}_{text,i} \parallel \mathbf{z}_{topo,i} \parallel \bar{y}_i] \quad (3.8)$$

3.3. Расчет эвристических признаков на гетерогенном графе

Для компенсации эффекта избыточного сглаживания графовых сверток рассчитывается набор парных структурных эвристик для ребер (u, v) , базирующийся на матричных операциях над разреженными представлениями:

1. Временная разница:

$$dt = y_u - y_v \quad (3.9)$$

2. Перекрывание авторских коллективов (Jaccard Overlap):

$$au_o = \frac{|A(u) \cap A(v)|}{|A(u) \cup A(v)|} \quad (3.10)$$

где $A(u)$ — множество соавторов статьи u .

3. Общие соседи (Common Neighbors):

$$cn = \log(|\mathcal{N}_{sym}(u) \cap \mathcal{N}_{sym}(v)| + 1.0) \quad (3.11)$$

Метрика CN рассчитывается в векторном виде через разреженное умножение матриц смежности:

$$CN = A_{sym} \cdot A_{sym}^T \quad (3.12)$$

4. Индекс Адамика-Адар (Adamic-Adar):

$$aa = \log \left(\sum_{w \in \mathcal{N}_{sym}(u) \cap \mathcal{N}_{sym}(v)} \frac{1}{\log(deg(w) + 1e - 8) + 1e - 8} + 1.0 \right) \quad (3.13)$$

где $deg(w)$ — степень промежуточного узла-посредника w .

3.4. Метод маскирования ребер и генерация негативных примеров

В соответствии с выбранной стратегией маскирования (85/5/10), все вершины графа присутствуют в матрице соавторства, однако ребра цитирования валидационной и тестовой выборок удаляются из структуры графовой агрегации сообщений, чтобы исключить утечку информации.

Для каждого положительного ребра цитирования (u, v) генерируется соответствующее отрицательное ребро (u, v_{neg}) . Процесс генерации подчинен жесткому причинно-следственному правилу:

$$v_{neg} \sim V \quad \text{in case} \quad y_{v_{neg}} \leq y_u \quad \text{and} \quad v_{neg} \neq u \quad (3.14)$$

Для повышения качества обучения во втором эксперименте используется механизм Hard Negative Sampling: отрицательные вершины выбираются из пула семантически наиболее близких по SciBERT-эмбедингам к истинной целевой статье v , но не имеющих реальной связи с источником u .

3.5. Архитектуры моделей: гомогенные и гетерогенные GNN и GBDT-ранжирование

Гомогенные графовые нейронные сети (Encoder-Predictor)

Реализован двухэтапный пайплайн, где на первом этапе графовый энкодер обновляет векторные представления вершин, а на втором - предиктор вычисляет оценку ребра.

Графовые энкодеры:

- **LightGCN:** Линейное агрегирование соседских представлений без весовых матриц и нелинейных активаций:

$$\mathbf{h}_i^{(l+1)} = \sum_{j \in \mathcal{N}(i)} \frac{1}{\sqrt{|\mathcal{N}(i)| |\mathcal{N}(j)|}} \mathbf{h}_j^{(l)} \quad (3.15)$$

- **SGC:** K -шаговое сглаживание признаков с последующей линейной проекцией:

$$\mathbf{z} = W \cdot (T^K \mathbf{x}) \quad (3.16)$$

- **SAGE (GraphSAGE):** Конкатенация признаков узла и агрегированного представления его соседей:

$$\mathbf{h}_i^{(l+1)} = \text{ReLU} \left(W_1 \mathbf{h}_i^{(l)} + W_2 \cdot \text{mean}_{j \in \mathcal{N}(i)} (\mathbf{h}_j^{(l)}) \right) \quad (3.17)$$

- **NeoGNN:** Гибридная архитектура, параллельно обрабатывающая семантические свертки и структурные эмбединги Adjacency, объединяя их на финальном слое.

Предикторы связи:

- **Standard Predictor:** Конкатенация векторов источника, цели, их поэлементного произведения (Hadamard), абсолютной разности и вектора эвристик с последующим MLP:

$$\mathbf{f} = [\mathbf{z}_u \parallel \mathbf{z}_v \parallel \mathbf{z}_u \odot \mathbf{z}_v \parallel |\mathbf{z}_u - \mathbf{z}_v| \parallel \mathbf{h}_{heur}] \quad (3.18)$$

- **BUDDY Predictor:** Позднее слияние (Late Fusion). Семантические векторы и вектор эвристик обрабатываются независимыми

полносвязными блоками, результаты которых конкатенируются перед финальной классификацией.

- **NCN Predictor:** Вектор признаков ребра опирается на попарное пересечение окрестностей и произведение Адамара:

$$\mathbf{f} = [(\mathbf{z}_u \odot \mathbf{z}_v) \parallel \mathbf{h}_{heur}] \quad (3.19)$$

Гетерогенные графовые нейронные сети

Реализована модель HeteroEncoder, выполняющая свертку на двудольном графе по типам связей:

$$\mathbf{h}_p^{(l+1)} = \text{SAGEConv}_{writes}(\mathbf{h}_a^{(l)}) + \text{SAGEConv}_{cites}(\mathbf{h}_p^{(l)}) \quad (3.20)$$

Данная схема позволяет напрямую агрегировать топологию авторов в векторы новых статей при холодном старте.

Градиентный бустинг (GBDT)

Построен табличный классификатор на базе CatBoostRanker. Для каждой пары (u, v) формируется вектор признаков, содержащий: эвристики (dt, au_o, cn, aa), косинусное сходство семантических векторов, косинусное сходство топологических векторов, а также разности и произведения векторов узлов. Обучение выполняется с оптимизацией YetiRank и QueryRMSE.

3.6. Оптимизация функций потерь (BPR, InfoNCE, Margin, Focal Loss, ASL)

Для оптимизации весов моделей под задачу ранжирования реализованы следующие функции потерь:

1. Bayesian Personalized Ranking (BPR Loss):

$$\mathcal{L}_{BPR} = -\frac{1}{|B|} \sum_{(u, v_p, v_n)} \log \sigma(S(u, v_p) - S(u, v_n)) \quad (3.21)$$

2. InfoNCE Loss:

$$\mathcal{L}_{InfoNCE} = -\frac{1}{|B|} \sum_{i=1}^{|B|} \log \frac{\exp(S(u, v_p)/\tau)}{\exp(S(u, v_p)/\tau) + \sum_j \exp(S(u, v_n^j)/\tau)} \quad (3.22)$$

3. Margin Loss:

$$\mathcal{L}_{Margin} = \frac{1}{|B|} \sum_{(u, v_p, v_n)} \max(0, S(u, v_n) - S(u, v_p) + m) \quad (3.23)$$

4. Focal Loss:

$$\mathcal{L}_{FL} = -\alpha(1 - p_t)^\gamma \log(p_t) \quad (3.23)$$

5. Asymmetric Loss (ASL):

Декопирует параметр затухания γ для положительных (γ_+) и отрицательных (γ_-) примеров:

$$\mathcal{L}_{ASL} = \begin{cases} -(1-p)^\gamma \log(p), & y = 1 \\ -p^{\gamma-} \log(1-p), & y = 0 \end{cases} \quad (3.24)$$

Это позволяет жестко штрафовать ложноположительные ответы при экстремальном дисбалансе классов.

3.7. Выводы по главе 3

1. Разработан и программно реализован на PyTorch комплексный конвейер извлечения семантических (SciBERT + Autoencoder) и топологических (FastRP) признаков.
2. Математически формализованы парные сетевые эвристики на разреженных матрицах, позволяющие учитывать соавторство и пересечение цитирований.
3. Реализован широкий спектр графовых сверточных архитектур (включая гетерогенные и гибридные NeoGNN) и предикативных моделей (Standard, BUDDY, NCN, CatBoostRanker).
4. Настроена система ранжирующих функций потерь (BPR, InfoNCE, Margin, ASL), адаптирующая градиентный спуск под максимизацию списочных метрик качества.

4. Анализ полученных результатов

4.1. Метрики оценки качества ранжирования (MRR, Hits@10)

Для оценки качества работы моделей применяются стандартные метрики рекомендательных систем:

1. Mean Reciprocal Rank (MRR): среднее значение величины, обратной рангу первого истинного кандидата в списке рекомендаций:

$$\text{MRR} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{\text{rank}_i} \quad (4.1)$$

где rank_i — позиция первой верной рекомендации для i -го запроса.

2. Hits@k (Доля верных предсказаний в топ-k): бинарный показатель наличия хотя бы одного истинного целевого узла в первых k позициях выдачи:

$$\text{Hits@k} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \mathbb{I}(\text{rank}_i \leq k) \quad (4.2)$$

Для каждого эксперимента строились графики обучения (loss train, loss val).

Для краткости будет приведен только график для лучшей обученной модели.

Результаты всех остальных моделей представлены в общей таблице. Для предотвращения переобучения используется early stopping.

3. Normalized Discounted Cumulative Gain (NDCG@k): нормализованный дисконтированный кумулятивный выигрыш. В отличие от Hits@k, данная метрика учитывает не только факт наличия верной рекомендации, но и её позицию в итоговой выдаче, сильнее штрафую за ошибки на верхних позициях:

$$NDCG@k = \frac{DCG@k}{IDCG@k}, \quad DCG@k = \sum_{i=1}^k \frac{rel_i}{\log_2(i+1)} \quad (4.3)$$

где $rel_i \in \{0, 1\}$ — бинарная релевантность i -го документа в выдаче, а $IDCG@k$ — идеальный показатель DCG (максимально возможный при данной разметке).

4.2. Результаты первого эксперимента: гомогенные GNN на графе цитирований

Для выявления оптимальной архитектуры был реализован автоматический подбор гиперпараметров (Grid Search) по сетке, включающей различные типы графовых энкодеров, предикторов и функций потерь. Полные результаты сеточного поиска вынесены в Приложение А.

Таблица 4.1. Результаты тестирования гомогенных моделей (фрагмент лучших конфигураций)

Архитектура	Предиктор	Лосс	mrr	hits10	ndcg10
NEOGNN	STANDARD	Margin	0.2094	0.4799	0.0889
LIGHTGCN	STANDARD	Margin	0.1900	0.4254	0.0739
LIGHTGCN	NCN	Margin	0.1634	0.3698	0.0704
SGC	STANDARD	Margin	0.1611	0.3786	0.0648

NEOGNN	NCN	Margin	0.1575	0.3592	0.0646
SGC	NCN	Margin	0.1351	0.3078	0.0567
BASELINE	Topo	Heuristics	0.1019	0.1820	0.0296

Топологический анализ и влияние функций потерь

В рамках первого этапа было проведено масштабное тестирование гомогенных графовых нейросетей. Выявлено, что наилучшую обобщающую способность демонстрирует гибридная архитектура NEOGNN с предиктором Standard и функцией потерь Margin Loss ($NDCG@10 = 0.0889$, $Hits@10 = 0.4799$).

Экспериментальные данные демонстрируют критическую важность выбора функции потерь. Полносвязные классификационные лоссы (Focal Loss, ASL) показывают результаты на уровне статистической погрешности ($NDCG@10 < 0.01$). В условиях сильно разреженных графов цитирования такие функции стремятся занулить оценки для подавляющего большинства кандидатов.

Ранжирующая функция Margin Loss успешно решает эту проблему. Она оптимизирует взаимное расстояние (зазор) между оценками истинной и ложной пар

Это сохраняет непрерывность шкалы оценок, необходимую для корректного ранжирования.

4.3. Результаты второго эксперимента: гетерогенное представление и GBDT-ранжирование

При переходе ко второму эксперименту (после выделения плотного ядра k -core и введения вершин авторов) были протестированы алгоритмы градиентного бустинга и гетерогенные нейросетевые модели. Полная таблица результатов находится в приложении Б.

График обучения лучшей модели:




Рисунок 5. График потерь на train и val лучшей модели
LightGCN+Buddy+BCE

По графику можно сделать вывод об отсутствии переобучения, так как линия обучения не превосходит линию валидации.

Результаты эксперимента:

Таблица 4.2. Результаты тестирования моделей на гетерогенном графе (Лучшие модели)

Архитектура	Предиктор	Лосс	Hub	mrr	hits10	ndcg10
LightGCN	BUDDY	BCE	True	0.3516	0.5950	0.2575
LightGCN	Standard	BCE	True	0.3355	0.5745	0.2377
MLP	BUDDY	BCE	True	0.3286	0.5665	0.2392
SAGE	BUDDY	BCE	True	0.3268	0.5617	0.2383
SAGE	Standard	BCE	True	0.3210	0.5533	0.2221
MLP	Standard	BCE	True	0.3076	0.5296	0.2036
GBDT	—	QueryRMSE	False	0.1188	0.2117	0.0610
CatBoost_Inductive	—	YetiRank	False	0.0774	0.1386	0.0429
GBDT_MM (Cold Start)	—	YetiRank	False	0.0138	0.0217	0.0052

Анализ предсказаний в условиях холодного старта

Переход ко второму эксперименту (эмуляция холодного старта для новых публикаций) выявил фундаментальные ограничения базовых подходов и позволил определить оптимальную архитектуру рекомендаций:

Эффективность двудольного агрегирования: Абсолютным лидером стала нейросетевая конфигурация LightGCN + BUDDY ($NDCG@10 = 0.2575$, $Hits@10 = 0.5950$). Механизм позднего слияния (Late Fusion) в предикторе BUDDY позволяет эффективно комбинировать слабые топологические сигналы от сети соавторов с семантическими эмбедами статьи, обеспечивая высокую точность даже при отсутствии исторических цитирований.

Критическая роль априорной центральности (Hub): Интеграция признака входящей степени целевой статьи (Hub=True) дает стабильный прирост метрик для всех GNN-моделей. Для лучшей конфигурации LightGCN + BUDDY этот признак увеличил NDCG@10 с 0.2204 до 0.2575. Это доказывает, что при структурном дефиците «хабовость» потенциального источника выступает надежным ориентиром для предсказания связи.

Деградация градиентного бустинга: В режиме строгого холодного старта принудительное зануление структурных эвристик (Common Neighbors, Adamic-Adar) приводит к коллапсу предсказательной способности GBDT. Метрика NDCG@10 падает до уровня случайного шума (0.0052). Это подтверждает, что табличные ансамбли критически зависят от наличия явных путей в графе, уступая гетерогенным графовым нейросетям в индуктивных сценариях.

4.4. Предсказание и оценка лучшего решения в условиях холодного старта

Анализ превосходства моделей прямого распространения (MLP) и гибридных алгоритмов (NeoGNN) над стандартными пространственными свертками на текстовых признаках позволяет сделать глубокие выводы о топологической структуре сети цитирования:

1. Низкая локальная семантическая гомофилия: В исследуемой сети цитирования по машинному обучению наблюдается эффект семантического разнообразия связей. Статьи часто цитируют работы из смежных или фундаментальных математических дисциплин (например, статья по

нейросетям цитирует базовую работу по оптимизации или линейной алгебре). Пространственные свертки гомогенных GNN принудительно усредняют эти разнородные семантические векторы, размывая ключевые терминологические различия (over-smoothing). MLP, оценивающий пары векторов без агрегации, сохраняет высокую семантическую точность.

2. Асимметрия и направленность сетевых процессов: Сети цитирования строго ориентированы во времени. Использование неориентированных сверток в классических GNN приносит колоссальный шум из будущего в прошлое. MLP и GBDT, использующие явный направленный признак $\Delta t = y_u - y_v$, сохраняют причинно-следственную структуру сети, что выражается в более высокой точности ранжирования.

4.5. Выводы по главе 4

1. Для гомогенных графов цитирования оптимальным выбором является гибридная модель NEOGNN в связке с ранжирующей функцией Margin Loss, предотвращающей эффект зануления градиентов на сильно разреженных данных.

2. В сценарии жесткого холодного старта использование классических табличных алгоритмов (GBDT) нецелесообразно из-за их критической зависимости от локальных эвристик пересечения окрестностей ($\text{NDCG}@10 \approx 0.005$).

3. Проблема холодного старта успешно решается применением гетерогенных архитектур. Связка LightGCN + BUDDY с использованием признаков хабовой центральности позволяет эффективно извлекать косвенный сигнал через

графы соавторства, достигая высокого качества рекомендаций ($NDCG@10 = 0.2575$, $Hits@10 = 0.5950$).

Заключение

В ходе выполнения курсовой работы была решена задача предсказания связей (рекомендации источников цитирования) для новых научных публикаций в условиях холодного старта.

В рамках исследования были получены следующие научные и практические результаты:

1. Разработана методология гетерогенного моделирования: для преодоления структурной изоляции новых публикаций гомогенный граф цитирований был преобразован в гетерогенный граф соавторства и цитирования. Это позволило транслировать топологические сигналы от исторических узлов к изолированным узлам через профили авторов. На основе данных платформы OpenAlex сформирован стабильный граф, содержащий 59 632 публикации по машинному обучению за последние 10 лет.

2. Проведен разведочный сетевой анализ графа: топологический анализ сети выявил степенной характер распределения степеней вершин и нелинейную динамику средней плотности связей. Установлено, что в периоды публикационных "бумов" (2017 и 2025–2026 гг.) сеть цитирования фрагментируется, характеризуясь низкой средней степенью вершин ($\approx 8-11$), тогда как в периоды затишья сеть уплотняется (≈ 25). Выявлены и алгоритмически скорректированы временные аномалии причинности

цитирования, вызванные пост-датированием выпусков журналов и обновлениями препринтов.

3. Экспериментально оценены гомогенные GNN-архитектуры. Доказано, что применение стандартных классификационных лоссов ведет к деградации модели на разреженных графах. Наилучшие результаты показала гибридная архитектура NEOGNN + Margin Loss ($\text{NDCG@10} = 0.0889$, $\text{Hits@10} = 0.4799$).

4. Оценена эффективность алгоритмов в условиях холодного старта. Выявлено, что градиентный бустинг (CatBoostRanker) полностью теряет предсказательную способность при отсутствии структурных связей у новой статьи (NDCG@10 падает до 0.0052). Данное ограничение успешно преодолено с помощью гетерогенного графового пайплайна LightGCN + BUDDY, который за счет агрегации авторского контекста и учета априорной центральности источников достиг высокой точности ранжирования ($\text{NDCG@10} = 0.2575$, $\text{Hits@10} = 0.5950$).

Перспективы развития работы заключаются в переходе от статического гетерогенного представления к динамическим графовым нейронным сетям (Temporal Graph Networks, TGN), способным непрерывно обновлять векторные представления авторов во времени, а также в интеграции более мощных языковых моделей для повышения качества исходного семантического кодирования аннотаций.

Список использованных источников

Основная литература:

1. Коротеев, М. В. Интеллектуальный анализ данных и машинное обучение : учебник / М. В. Коротеев. — Москва : Финансовый университет, 2023. — 248 с. — ISBN 978-5-7942-1681-4.
2. Кочкаров, А. А. Экспериментальная теория графов и алгоритмы анализа сетевых моделей : учебное пособие / А. А. Кочкаров, С. В. Макрушин, В. Е. Каменчук. — Москва : КноРус, 2024. — 160 с. — ISBN 978-5-406-12836-6.
3. Шитиков, В. К. Сетевой анализ структуры экосистем и алгоритмы теории графов / В. К. Шитиков, Г. С. Розенберг // Самарская Лука: проблемы региональной и глобальной экологии. — 2021. — Т. 30, № 2. — С. 15–32.
4. Beltagy, I. SciBERT: A Pretrained Language Model for Scientific Text / I. Beltagy, K. Lo, A. Cohan // arXiv preprint. — 2019. — arXiv:1903.10676. — 15 p.
5. Chen, H. Fast and Accurate Network Embeddings via Very Sparse Random Projection / H. Chen, M. Yin, W. Wang // arXiv preprint. — 2019. — arXiv:1908.11512. — 10 p.
6. Chen, D. Measuring and Relieving the Over-smoothing Problem for Graph Neural Networks from the Topological View / D. Chen, Y. Lin, W. Li [et al.] // arXiv preprint. — 2019. — arXiv:1909.03211. — 9 p.
7. Hamilton, W. L. Inductive Representation Learning on Large Graphs / W. L. Hamilton, R. Ying, J. Leskovec // arXiv preprint. — 2017. — arXiv:1706.02216. — 19 p.
8. He, X. LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation / X. He, K. Deng, X. Wang [et al.] // arXiv preprint. — 2020. — arXiv:2002.02126. — 13 p.
9. Oord, A. v. d. Representation Learning with Contrastive Predictive Coding / A. v. d. Oord, Y. Li, O. Vinyals // arXiv preprint. — 2018. — arXiv:1807.03748. — 13 p.
10. Rendle, S. BPR: Bayesian Personalized Ranking from Implicit Feedback / S. Rendle, C. Freudenthaler, Z. Gantner [et al.] // arXiv preprint. — 2012. — arXiv:1205.2618. — 14 p.
11. Wu, F. Simplifying Graph Convolutional Networks / F. Wu, A. Souza, T. Zhang [et al.] // arXiv preprint. — 2019. — arXiv:1902.07153. — 11 p.

Приложение А: Таблица первого эксперимента

архитектура	предиктор	лосс	mrr	rec10	hits10	ndcg10
NEOGNN	STANDARD	Margin	0.2094	0.0639	0.4799	0.0889
LIGHTGCN	STANDARD	Margin	0.19	0.0528	0.4254	0.0739
SGC	STANDARD	Margin	0.1611	0.0482	0.3786	0.0648
LIGHTGCN	NCN	Margin	0.1634	0.0522	0.3698	0.0704
NEOGNN	NCN	Margin	0.1575	0.0472	0.3592	0.0646
SGC	NCN	Margin	0.1351	0.0415	0.3078	0.0567
DIRGCN	NCN	BPR	0.1001	0.026	0.2412	0.0357
LIGHTGCN	BUDDY	Margin	0.1283	0.025	0.2358	0.0399
DIRGCN	STANDARD	BPR	0.0919	0.0204	0.2109	0.0291
SAGE	STANDARD	Margin	0.1108	0.018	0.2038	0.0298
DIRGCN	STANDARD	Margin	0.1132	0.0169	0.1953	0.0298
BASELINE	Topo	Heuristics	0.1019	0.0165	0.182	0.0296
SGC	BUDDY	Margin	0.1047	0.0194	0.1711	0.0314
DIRGCN	STANDARD	InfoNCE	0.1244	0.014	0.167	0.0281
SGC	NCN	BPR	0.0664	0.0154	0.1554	0.0209
SAGE	NCN	BPR	0.0681	0.0148	0.1537	0.0208
NEOGNN	STANDARD	BPR	0.0633	0.012	0.1452	0.0165
DIRGCN	NCN	Margin	0.0756	0.0117	0.1386	0.0189
MLP	NCN	InfoNCE	0.1045	0.0112	0.1374	0.0253
LIGHTGCN	NCN	BPR	0.0608	0.0128	0.1348	0.0178
SAGE	NCN	Margin	0.1	0.0108	0.1314	0.0229
MLP	NCN	Margin	0.0801	0.0104	0.1292	0.0205
LIGHTGCN	STANDARD	BPR	0.0585	0.0107	0.1285	0.0155
SGC	BUDDY	BPR	0.0762	0.0117	0.1272	0.0201
SGC	STANDARD	BPR	0.0555	0.011	0.1195	0.0152
DIRGCN	BUDDY	InfoNCE	0.1047	0.009	0.1178	0.023
MLP	STANDARD	ASL	0.103	0.0092	0.1173	0.0233
MLP	STANDARD	Margin	0.0731	0.0087	0.1129	0.018
MLP	STANDARD	InfoNCE	0.0704	0.0085	0.1086	0.0176
SAGE	STANDARD	InfoNCE	0.048	0.008	0.1081	0.0135

MLP	BUDDY	InfoNCE	0.1005	0.0079	0.1042	0.0216
SAGE	BUDDY	InfoNCE	0.0176	0.0075	0.1037	0.0075
MLP	BUDDY	Margin	0.0219	0.0075	0.0989	0.0084
NEOGNN	NCN	BPR	0.0449	0.0086	0.0979	0.0115
SAGE	STANDARD	BPR	0.0326	0.006	0.0691	0.0077
NEOGNN	BUDDY	Margin	0.0391	0.0056	0.0613	0.0084
NEOGNN	BUDDY	BPR	0.0308	0.0048	0.0543	0.007
MLP	STANDARD	FL	0.0144	0.0034	0.0465	0.0035
MLP	NCN	BPR	0.0237	0.0035	0.0448	0.005
SAGE	NCN	InfoNCE	0.0237	0.0032	0.0407	0.0045
MLP	STANDARD	BPR	0.0209	0.003	0.0351	0.0038
SAGE	BUDDY	ASL	0.0217	0.0028	0.0334	0.0054
SGC	BUDDY	ASL	0.0276	0.003	0.0325	0.0066
NEOGNN	BUDDY	FL	0.0191	0.0025	0.0281	0.0048
LIGHTGCN	BUDDY	FL	0.019	0.0021	0.0235	0.0044
LIGHTGCN	BUDDY	BPR	0.0117	0.002	0.0216	0.0027
NEOGNN	NCN	InfoNCE	0.0118	0.0018	0.0196	0.0021
LIGHTGCN	NCN	InfoNCE	0.0077	0.0009	0.0131	0.0014
SAGE	BUDDY	BPR	0.0073	0.001	0.0124	0.0014
SGC	NCN	InfoNCE	0.0062	0.0008	0.0121	0.0014
DIRGCN	BUDDY	ASL	0.0069	0.0011	0.0116	0.0017
SGC	NCN	FL	0.0083	0.0009	0.0114	0.0018
SGC	BUDDY	FL	0.0055	0.0011	0.0111	0.0012
LIGHTGCN	NCN	ASL	0.0064	0.0007	0.0107	0.0012
MLP	BUDDY	FL	0.0048	0.0009	0.0102	0.0011
MLP	NCN	FL	0.0053	0.0007	0.0102	0.0009
NEOGNN	NCN	FL	0.0067	0.0007	0.0097	0.0011
DIRGCN	NCN	ASL	0.0055	0.0006	0.0095	0.0011
NEOGNN	BUDDY	ASL	0.0057	0.001	0.0095	0.0013
SAGE	BUDDY	FL	0.0112	0.0009	0.009	0.0014
DIRGCN	BUDDY	FL	0.0054	0.0009	0.009	0.0013
MLP	BUDDY	BPR	0.0062	0.0006	0.0087	0.001
LIGHTGCN	NCN	FL	0.0065	0.0005	0.0082	0.0012
LIGHTGCN	BUDDY	ASL	0.0048	0.0009	0.008	0.0009

SGC	NCN	ASL	0.0057	0.0007	0.0073	0.001
MLP	BUDDY	ASL	0.0062	0.0004	0.007	0.0007
DIRGCN	NCN	FL	0.0053	0.0005	0.0068	0.0009
MLP	NCN	ASL	0.0043	0.0004	0.0065	0.0006
SAGE	BUDDY	Margin	0.008	0.0005	0.0063	0.0006
NEOGNN	NCN	ASL	0.0067	0.0004	0.0063	0.0009
SAGE	STANDARD	ASL	0.006	0.0004	0.0061	0.0007
SAGE	STANDARD	FL	0.0081	0.0004	0.0061	0.0007
DIRGCN	NCN	InfoNCE	0.0053	0.0005	0.0058	0.0006
LIGHTGCN	BUDDY	InfoNCE	0.0033	0.0005	0.0048	0.0008
SAGE	NCN	FL	0.004	0.0003	0.0044	0.0004
SAGE	NCN	ASL	0.004	0.0002	0.0039	0.0004
DIRGCN	STANDARD	FL	0.0032	0.0002	0.0039	0.0004
LIGHTGCN	STANDARD	InfoNCE	0.0025	0.0002	0.0036	0.0003
LIGHTGCN	STANDARD	ASL	0.0035	0.0002	0.0034	0.0005
SGC	BUDDY	InfoNCE	0.0039	0.0005	0.0034	0.0008
NEOGNN	STANDARD	FL	0.0029	0.0002	0.0034	0.0005
LIGHTGCN	STANDARD	FL	0.0026	0.0002	0.0032	0.0004
SGC	STANDARD	ASL	0.0032	0.0002	0.0032	0.0004
NEOGNN	STANDARD	InfoNCE	0.0023	0.0002	0.0029	0.0003
DIRGCN	STANDARD	ASL	0.003	0.0002	0.0027	0.0003
NEOGNN	BUDDY	InfoNCE	0.0028	0.0002	0.0027	0.0004
DIRGCN	BUDDY	Margin	0.0033	0.0005	0.0024	0.0006
NEOGNN	STANDARD	ASL	0.0031	0.0001	0.0024	0.0004
SGC	STANDARD	InfoNCE	0.0018	0.0002	0.0022	0.0003
SGC	STANDARD	FL	0.0037	0.0001	0.0022	0.0004
DIRGCN	BUDDY	BPR	0.0018	0.0003	0.0005	0.0003
GBDT	None	YetiRank	0.0598	0.0225	0.0898	0.0236
GBDT	None	QueryRMSE	0.0759	0.0332	0.1241	0.0326
GBDT	None	YetiRank	0.0239	0.0086	0.0418	0.0065
GBDT	None	QueryRMSE	0.0597	0.0225	0.0897	0.0237
GBDT	None	YetiRank	0.0612	0.0228	0.091	0.024
GBDT	None	QueryRMSE	0.1188	0.068	0.2117	0.061
GBDT	None	YetiRank	0.0692	0.0288	0.1106	0.0283

GBDT	None	QueryRMSE	0.1151	0.0658	0.2046	0.0588
GBDT	None	YetiRank	0.0721	0.0362	0.1411	0.0343
GBDT	None	QueryRMSE	0.0713	0.0377	0.1455	0.0344
GBDT	None	YetiRank	0.0741	0.0373	0.1447	0.0354
GBDT	None	QueryRMSE	0.0711	0.0375	0.1449	0.0343
GBDT	None	YetiRank	0.0715	0.0361	0.1405	0.0341
GBDT	None	QueryRMSE	0.0655	0.0338	0.1338	0.0312
GBDT	None	YetiRank	0.0724	0.0369	0.1429	0.0347
GBDT	None	QueryRMSE	0.0663	0.0338	0.1338	0.0313
GBDT_MM	None	YetiRank	0.0113	0.0042	0.0202	0.0044
GBDT_MM	None	QueryRMSE	0.0014	0.0003	0.0018	0.0003
GBDT_MM	None	YetiRank	0.0124	0.0041	0.02	0.0046
GBDT_MM	None	QueryRMSE	0.0014	0.0003	0.0018	0.0003
GBDT_MM	None	YetiRank	0.0135	0.0045	0.0212	0.005
GBDT_MM	None	QueryRMSE	0.0093	0.0035	0.0171	0.0035
GBDT_MM	None	YetiRank	0.0138	0.0046	0.0217	0.0052
GBDT_MM	None	QueryRMSE	0.0093	0.0035	0.0171	0.0035
V2_GBDT_MM	None	YetiRank	0.0118	0.0043	0.0206	0.0046
V2_GBDT_MM	None	QueryRMSE	0.0014	0.0003	0.0019	0.0003
V2_GBDT_MM	None	YetiRank	0.0113	0.0041	0.0198	0.0043
CatBoost_Inductive	None	YetiRank	0.0636	0.0423	0.1288	0.0354
CatBoost_Inductive	None	QueryRMSE	0.0593	0.0408	0.1203	0.0339
CatBoost_Inductive	None	YetiRank	0.0635	0.0423	0.1285	0.0353
CatBoost_Inductive	None	QueryRMSE	0.0587	0.0408	0.1198	0.0335
CatBoost_Inductive	None	YetiRank	0.0774	0.0479	0.1386	0.0429
CatBoost_Inductive	None	QueryRMSE	0.0602	0.0465	0.1302	0.0366
NN	None	none_standard	0.3076	0.2388	0.5296	0.2036

Приложение Б: Таблица второго эксперимента

архитектура	предиктор	лосс	hub	mrr	rec10	hits10	ndcg10
NN	lightgcn	buddy	TRUE	0.3516	0.3054	0.595	0.2575
NN	lightgcn	standard	TRUE	0.3355	0.2846	0.5745	0.2377
NN	none	buddy	TRUE	0.3286	0.2857	0.5665	0.2392
NN	none	buddy	TRUE	0.3286	0.2857	0.5665	0.2392
NN	sage	buddy	TRUE	0.3268	0.2836	0.5617	0.2383
NN	sage	standard	TRUE	0.321	0.2645	0.5533	0.2221
NN	none	buddy	FALSE	0.3047	0.2646	0.5338	0.2196
NN	none	buddy	FALSE	0.3047	0.2646	0.5338	0.2196
NN	none	standard	TRUE	0.3076	0.2388	0.5296	0.2036
NN	none	standard	TRUE	0.3076	0.2388	0.5296	0.2036
NN	lightgcn	standard	FALSE	0.285	0.2592	0.5268	0.2065
NN	lightgcn	buddy	FALSE	0.319	0.2583	0.5268	0.2204
NN	lightgcn	ncn	TRUE	0.2952	0.2557	0.5223	0.209
NN	sage	buddy	FALSE	0.2859	0.2575	0.5216	0.2071
NN	sage	ncn	TRUE	0.3003	0.2423	0.5178	0.2036
NN	none	ncn	TRUE	0.2873	0.2345	0.5146	0.1945
NN	none	ncn	TRUE	0.2873	0.2345	0.5146	0.1945
NN	sage	standard	FALSE	0.2671	0.2343	0.5075	0.1867
NN	none	standard	FALSE	0.2587	0.2088	0.472	0.1722
NN	none	standard	FALSE	0.2587	0.2088	0.472	0.1722
NN	lightgcn	ncn	FALSE	0.2294	0.2068	0.4418	0.1638
NN	none	ncn	FALSE	0.2224	0.1792	0.4217	0.1455
NN	none	ncn	FALSE	0.2224	0.1792	0.4217	0.1455
NN	sage	ncn	FALSE	0.2125	0.1789	0.4136	0.1412

Приложение В: программный код

Программный код находится по ссылке на github проекта:

<https://github.com/kvdep/Analysing-machine-learning-citations-graph-using-neural-networks>