

Тема: Применение методов машинного обучения для анализа сетей цитирования научных работ

Выполнил: студент группы Пм23-1 Кидысюк Александр Владимирович
Научный руководитель: Мацеевич С.В.

Москва, 2026

Актуальность

- Экспоненциальный рост научной литературы усложняет поиск релевантных источников.
- Проблема "холодного старта": новые публикации не имеют связей в графе цитирований, поэтому классические сетевые методы к ним неприменимы.
- Гипотеза: использование графовых нейронных сетей (GNN) поверх двудольного графа (автор-статья) совместно с семантикой текста способно решить проблему холодного старта.

Цели и задачи

Цель:

Разработка и топологический анализ эффективности моделей ML для предсказания связей в условиях холодного старта - предсказание цитирований для новых научных статей.

Задачи:


1. Сбор и k-core очистка данных (OpenAlex).
2. Векторизация семантики (SciBERT + Autoencoder) и топологии (FastRP).
3. Обучение и сравнение гомогенных GNN.
4. Оценка гетерогенных GNN и классического бустинга (GBDT) в условиях холодного старта.

Методы: Данные и Признаки

Данные: ~60 000 статей по машинному обучению, отобранные методом k-core (k=3).

Вершины: Train: 50688, Val: 2981, Test: 593

Ребер в Train: 101719



1. Распределение вершин на train, val, test по годам

Методы: Данные и Признаки

Все ребра цитирования на Test, Val были маскированы при обучении.

Features:

Семантика: Векторы SciBERT сжаты полносвязным Autoencoder до размерности 256.

Топология: Вычисление глобальных свойств графа методом Fast Random Projection (FastRP).

Эвристики:


Год публикации, разница в годах

Пересечение авторов (Жаккар)

Общие соседи

Adamic-Adar

Входящая степень вершины



2. Heatmap цитирований по годам

Методы: Архитектуры моделей

Эксперимент 1 (Гомогенный граф):

Архитектуры: GCN, GraphSAGE, LightGCN, NeoGNN, CatBoost

Функции потерь:

Focal Loss, ASL, InfoNCE, BPR, Margin Loss.

Эксперимент 2 (Гетерогенный граф): введение вершин-авторов

Архитектуры: графовые нейросети

Добавлен признак входящей степени вершины.

Результаты: Гомогенный граф

Архитектура	Предиктор	Лосс	mrr	hits10	ndcg10
NEOGNN	STANDARD	Margin	0.2094	0.4799	0.0889
LIGHTGCN	STANDARD	Margin	0.19	0.4254	0.0739
SGC	STANDARD	Margin	0.1611	0.3786	0.0648
LIGHTGCN	NCN	Margin	0.1634	0.3698	0.0704
NEOGNN	NCN	Margin	0.1575	0.3592	0.0646
SGC	NCN	Margin	0.1351	0.3078	0.0567
GBDT	None	YetiRank	0.0598	0.0898	0.0236
GBDT	None	QueryRMSE	0.0759	0.1241	0.0326
GBDT_MM	None	YetiRank	0.0113	0.0202	0.0044
GBDT_MM	None	QueryRMSE	0.0014	0.0018	0.0003
V2_GBDT_MM	None	YetiRank	0.0118	0.0206	0.0046
V2_GBDT_MM	None	QueryRMSE	0.0014	0.0019	0.0003
CatBoost_Inductive	None	YetiRank	0.0636	0.1288	0.0354
CatBoost_Inductive	None	QueryRMSE	0.0593	0.1203	0.0339

Результаты: Гетерогенный граф

Архитектура	Предиктор	hub	mrr	hits10	ndcg10
lightgcn	buddy	TRUE	0.3516	0.595	0.2575
lightgcn	standard	TRUE	0.3355	0.5745	0.2377
none	buddy	TRUE	0.3286	0.5665	0.2392
none	buddy	TRUE	0.3286	0.5665	0.2392
sage	buddy	TRUE	0.3268	0.5617	0.2383
sage	standard	TRUE	0.321	0.5533	0.2221
none	buddy	FALSE	0.3047	0.5338	0.2196
none	buddy	FALSE	0.3047	0.5338	0.2196
none	standard	TRUE	0.3076	0.5296	0.2036
none	standard	TRUE	0.3076	0.5296	0.2036
lightgcn	standard	FALSE	0.285	0.5268	0.2065
lightgcn	buddy	FALSE	0.319	0.5268	0.2204
lightgcn	ncn	TRUE	0.2952	0.5223	0.209
sage	buddy	FALSE	0.2859	0.5216	0.2071
sage	ncn	TRUE	0.3003	0.5178	0.2036
none	ncn	TRUE	0.2873	0.5146	0.1945

Заключение

1. В гомогенных графах оптимальна связка NEOGNN + Margin Loss.
2. Табличные алгоритмы (GBDT) неприменимы для индуктивных графовых задач (холодного старта).
3. Гетерогенный пайплайн (LightGCN + BUDDY) успешно компенсирует отсутствие связей через двудольную сеть соавторов и признак хаба.
4. Точное предсказание цитирований ограничено высокой стохастичностью выбора авторов.

Источники

1. Коротеев, М. В. Интеллектуальный анализ данных и машинное обучение : учебник / М. В. Коротеев. — Москва : Финансовый университет, 2023. — 248 с. — ISBN 978-5-7942-1681-4.
2. Кочкаров, А. А. Экспериментальная теория графов и алгоритмы анализа сетевых моделей : учебное пособие / А. А. Кочкаров, С. В. Макрушин, В. Е. Каменчук. — Москва : КноРус, 2024. — 160 с. — ISBN 978-5-406-12836-6.
3. Шитиков, В. К. Сетевой анализ структуры экосистем и алгоритмы теории графов / В. К. Шитиков, Г. С. Розенберг // Самарская Лука: проблемы региональной и глобальной экологии. — 2021. — Т. 30, № 2. — С. 15-32.
4. Beltagy, I. SciBERT: A Pretrained Language Model for Scientific Text / I. Beltagy, K. Lo, A. Cohan // arXiv preprint. - 2019. - arXiv:1903.10676. - 15 p.
5. Chen, H. Fast and Accurate Network Embeddings via Very Sparse Random Projection / H. Chen, M. Yin, W. Wang // arXiv preprint. - 2019. - arXiv:1908.11512. - 10 p.